


ADIDAS US MARKET ANALYSIS




Predicción de Ventas con Machine Learning

Pipeline · GridSearchCV · 5 Modelos Comparados

Flujo de trabajo técnico completo | Dataset: 9.648 registros

Flujo de Trabajo

Pipeline completo de desarrollo del modelo predictivo



Conceptos claves:

- Se usa Pipeline para organizar, automatizar y estandarizar el proceso de preparación de datos y entrenamiento.
- Se usa GridSearchCV para encontrar automáticamente los mejores hiperparametros para un modelo.

El Dataset

Adidas US Sales · 9.648 registros × 14 columnas — sin valores nulos

9.648

Registros

14

Columnas

0

Valores Nulos

6

Variables cat.

#	Columna	Tipo	Descripción
0	Retailer	object	Nombre del distribuidor
1	Retailer ID	int64	ID único del distribuidor
2	Invoice Date	datetime64[ns]	Fecha de factura
3	Region	object	Región geográfica de EEUU
4	State / City	object	Estado y ciudad
5	Product	object	Categoría de producto Adidas
6	Price per Unit	float64	Precio unitario (USD)
7	Units Sold	int64	Unidades vendidas
8	Total Sales ★	float64	Ventas totales — TARGET del modelo
9	Operating Profit	float64	Beneficio operativo
10	Operating Margin	float64	Margen operativo (%)
11	Sales Method	object	Canal de venta

Limpieza · Feature Engineering · One-Hot Encoding

Ingeniería de Variables

Invoice Date → Month, Year, DayOfWeek, Is_Weekend

Retailer (6) → 6 columnas binarias (OHE)

Region (5) → 5 columnas binarias (OHE)

Product (6) → 6 columnas binarias (OHE)

Sales Method → 3 columnas binarias (OHE)

Variables Predictoras Finales (25)

Numéricas (5)

Price per Unit · Month · Year · DayOfWeek · Is_Weekend

Retailer (6)

Foot Locker · West Gear · Sports Direct · Kohl's · Amazon · Walmart

Region (5)

West · Northeast · Midwest · South · Southeast

Product (6)

Men's Street · Men's Athletic · Men's Apparel · Women's Street · Women's Apparel · Women's Athletic

Sales Method (3)

Online · Outlet · In-store



Variable TARGET: Total Sales (importe en USD de cada transacción)

División Train/Test · Escalado StandardScaler

TRAIN — 80% (7.718 filas)

**TEST
20%**

```
train_test_split(X, y, test_size=0.2, random_state=42)
```

sklearn.pipeline.Pipeline — evita Data Leakage

X_train / X_test

Datos de entrada

StandardScaler

fit() solo en train
transform() en ambos

Modelo ML

RF / XGB / LR
/ SVR / KNN

Predicciones

$\hat{y}$ (USD)



El escalado dentro del Pipeline garantiza validación cruzada correcta: `StandardScaler.fit()` se llama solo sobre `X_train` de cada fold.


Modelos Entrenados y Optimización

GridSearchCV con validación cruzada 3-fold sobre el pipeline completo

LR	RF	XGB	SVR	KNN
Linear Regression	Random Forest	XGBoost	SVR	KNN
Hiperparámetros: Sin hiperparámetros Base de referencia scoring: neg_MSE · cv=3	Hiperparámetros: n_estimators: [50,100] max_depth: [10,20,None] min_samples_split:[2,5] scoring: neg_MSE · cv=3	Hiperparámetros: n_estimators: [50,100] learning_rate: [0.05,0.1] max_depth: [3,5] scoring: neg_MSE · cv=3	Hiperparámetros: C: [0.1,1,10] epsilon: [0.01,0.1] kernel: [linear, rbf] scoring: neg_MSE · cv=3	Hiperparámetros: n_neighbors: [3,5,7] weights: [uniform, distance] scoring: neg_MSE · cv=3

Comparativa de Modelos — MAE

Mean Absolute Error (USD) — menor es mejor · error medio absoluto por predicción



Random Forest

MAE: \$25.359

RMSE: \$51.771

MEJOR · MAE más bajo

XGBoost

MAE: \$30.054

RMSE: \$63.503

2º · muy cercano a RF

KNN

MAE: \$69.365

RMSE: \$109.777

Error ≈ 2.7× el de RF

SVR

MAE: \$70.181

RMSE: \$147.686

Error ≈ 2.8× el de RF

Linear Reg.

MAE: \$80.248


RMSE: \$108.059

Peor MAE — modelo base

 **MAE vs  RMSE:** El MAE (\$25.359 en RF) es más interpretable — es el error típico en USD por venta. El RMSE (\$51.771) es siempre $\geq$ MAE porque penaliza más los errores grandes al elevarlos al cuadrado.

Comparativa de Modelos — RMSE

Root Mean Square Error (USD) — menor es mejor



Random Forest

RMSE: \$51.771

MAE: \$25.359

R²: 0.8686 | MEJOR MODELO

XGBoost

RMSE: \$63.503

MAE: \$30.054

R²: 0.8023 | 2º mejor

Linear Reg.

RMSE: \$108.059

MAE: \$80.248

R²: 0.4275 | Referencia

4 KNN

RMSE: \$109.777

MAE: \$69.365

R²: 0.4092 | Similar a LR

5 SVR


RMSE: \$147.686

MAE: \$70.181

R²: -0.069 | Peor modelo

Comparativa de Modelos — R^2

Coefficiente de determinación — mayor es mejor (máx. 1.0 = predicción perfecta)



Interpretación del R^2 : valores > 0.8 indican muy buen ajuste. SVR con R^2 negativo no supera ni a un modelo que predice siempre la media.

Tabla de Métricas — Comparativa Final

Resultados sobre el conjunto de TEST (20% = 1.930 muestras no vistas durante el entrenamiento)

 **RMSE** (Root Mean Squared Error): penaliza más los errores grandes — útil para detectar predicciones muy alejadas.  **MAE** (Mean Absolute Error): error medio absoluto en USD por predicción — más intuitivo para negocio.

Modelo	RMSE (USD) ↓	MAE (USD) ↓	R ² ↑	Mejor Hiperpar.	Ranking
 Random Forest	51.771	25.359	0.8686	n_est=100, depth=20	1º
 XGBoost	63.503	30.054	0.8023	lr=0.1, depth=5, n=100	2º
Linear Reg.	108.059	80.248	0.4275	Sin tunear	3º
KNN	109.777	69.365	0.4092	k=7, weights=uniform	4º
SVR	147.686	70.181	-0.069	C=10, ε=0.01, kernel=linear	5º

 **Modelo Seleccionado: Random Forest**
RMSE \$51.771 (menor error cuadrático) · MAE \$25.359 (en promedio se equivoca \$25.359 por predicción) · R² 0.8686 · 52% mejor que Regresión Lineal

¿Por qué Random Forest es el Mejor Modelo?

Análisis de la selección del modelo de producción

RMSE

51.771

USD

↓ mejor

MAE

25.359

USD

↓ mejor

Mayor $R^2 = 0.8686$

Explica el 86.9% de la varianza de ventas. XGBoost queda en 80.2%. Los modelos lineales no alcanzan ni el 43%.

Robustez ante outliers

Al ser un ensemble de árboles, Random Forest es naturalmente resistente a valores atípicos en precio o volumen.

RMSE + MAE más bajos

RMSE \$51.771 (19% mejor que XGBoost) y MAE \$25.359 — en promedio el modelo se equivoca solo \$25.359 por predicción.

Hiperparámetros óptimos

Tras GridSearchCV: `n_estimators=100`, `max_depth=20`, `min_samples_split=2`. Configuración validada con 3-fold CV.

Captura no linealidad

El dataset mezcla retailers, regiones y productos con interacciones complejas que un modelo lineal no puede aprender.

Predicción Final — Ejemplo Real

Aplicación del modelo de producción guardado en mejor_modelo_produccion.pkl

Predicción del Modelo

\$319.769

USD estimados de ventas totales

muestra: X_test.iloc[0]

Valor Real en Test

\$200.000

USD ventas reales registradas

y_test.iloc[0]

Análisis del Error en este Ejemplo

Error absoluto: \$119.769 USD | Este caso específico supera el RMSE global del modelo (\$51.771), lo que es normal: el RMSE es el promedio de todos los errores al cuadrado. Algunos casos tendrán mayor error y otros menor.

 Flujo de producción: nueva_entrada = X_test.iloc[[0]] → mejor_modelo.predict(nueva_entrada) → \$319.769

Conclusiones

01

Random Forest es el modelo elegido

RMSE \$51.771 · MAE \$25.359 · R^2 0.87 sobre test set. En promedio el modelo acierta con un error de solo \$25.359 por predicción.

03

OHE amplía el poder predictivo

Pasar de 12 columnas originales a 25 variables mediante One-Hot Encoding permite capturar el efecto de cada retailer, región y producto.

02

Pipeline garantiza validez metodológica

El StandardScaler se ajusta solo sobre datos de entrenamiento en cada fold, eliminando data leakage y asegurando métricas fiables.

04

SVR y KNN no son adecuados para este caso

SVR: R^2 negativo y MAE \$70.181. KNN: MAE \$69.365. La no linealidad del dataset requiere modelos basados en árboles.